

Aprendizado de máquina - atividade discente supervisionada 1

Prof. Mozart Hasse

LEIA ATENTAMENTE TODAS AS INSTRUÇÕES ATÉ O FINAL DA ÚLTIMA PÁGINA. CADA PALAVRA CONTA!

Use exclusivamente os dados da base pública fornecida pelo professor. Descubra tipos, faixas de valores e distribuições através de análise exploratória. Dados a usar: base do CAGED de Curitiba e região metropolitana, dos meses novembro (2024 e 2025), dezembro (2024 e 2025) e janeiro (2024 e 2025). Há dados de outros meses, que a equipe precisa entender por quê eles vieram e por quê o professor recomenda ignorá-los.

Ajustes adicionais poderão ser necessários dependendo do algoritmo escolhido.

O que o algoritmo de aprendizado de máquina implementado pela equipe deve fazer é PREVER O VALOR DA COLUNA saldomovimentacao, com base em todos os outros campos fornecidos, para o mês de JANEIRO/2026.

SUA IMPLEMENTAÇÃO DEVE RECEBER COMO ENTRADA O ARQUIVO FORNECIDO PELO PROFESSOR E GERAR COMO SAÍDA UM ARQUIVO CONTENDO OS MESMOS DADOS DO ARQUIVO DE ENTRADA, TENDO CADA LINHA ACRESCIDA COM A PREVISÃO CORRESPONDENTE DA COLUNA saldomovimentacao.

NÃO É PERMITIDO complementar estes dados com informações de outras bases de dados, use apenas os dados fornecidos no arquivo ou valores deduzidos através de fórmulas. Se quiser e achar conveniente, pode usar os dados dos meses anteriores e montar seu classificador/regressor com base em quaisquer totalizações ou cálculos executados sobre o período fornecido.

Não custa avisar que a base fornecida NÃO FOI planejada nem tem como ser eficiente com algoritmos de séries temporais. O objetivo é usar um classificador e/ou

regressor. Não há como esperar um classificador com grande poder preditivo pois não está incluída na base nenhuma espécie de indicador econômico ou de variação nos períodos, que obviamente são fatores relevantes para fazer a previsão mas que não fazem parte deste trabalho devido ao prazo disponível.

Você precisará tratar os dados antes de aplicar o algoritmo:

- Selecionar campos relevantes
- Tratar nulos
- Agrupar ou totalizar linhas
- Se alguma conversão de dados for feita, você terá de converter também os dados fornecidos no dataset de teste para fazer as previsões. O importante é manter o leiaute proposto no arquivo de saída solicitado.

Dicionário de Dados — Novo CAGED (microdados de movimentação)

Campo	Tipo	Descrição	Valores / Observações
competênciamov	int	Mês da movimentação	Formato YYYYMM
região	int	Região geográfica (IBGE)	1 Norte, 2 Nordeste, 3 Sudeste, 4 Sul, 5 Centro-Oeste
uf	int	Unidade da Federação	Código IBGE
município	int	Município	Código IBGE (7 dígitos)
seção	string	Seção CNAE	Letra (A–U)
subclasse	int	CNAE 2.0 subclasse	7 dígitos
saldomovimentação	int	Tipo agregado de movimentação	1 admissão, -1 desligamento
cbo2002ocupação	int	Código da ocupação	Tabela CBO 2002
categoria	int	Categoria do vínculo	Ex: 101 = empregado CLT
grauinstrução	int	Escolaridade	1 a 8 (ver abaixo)
idade	int	Idade do trabalhador	Em anos
horascontratuais	string	Jornada semanal	Formato com vírgula (ex: 44,00)
raçacor	int	Raça/cor	1 branca, 2 preta, 3 parda, 4 amarela, 5 indígena, 9 ignorado

sexo	int	Sexo	1 masc, 2 fem, 3 não informado
tipoempregador	int	Tipo do empregador	0 PJ, 1 PF
tipoestabelecimento	int	Tipo do estabelecimento	1 empresa (outros possíveis)
tipodedeficiência	int	Tipo de deficiência	0 nenhuma
indtrabintermitente	int	Trabalho intermitente	0 não, 1 sim
indtrabparcial	int	Trabalho parcial	0 não, 1 sim
salário	float	Salário mensal total	Pode incluir variáveis
tamestabjan	int	Tamanho do estabelecimento	Faixas (1 até 8+)
indicadoraprendiz	int	Indica aprendiz	0 não, 1 sim
origemdainformação	int	Origem do dado	1 eSocial, 2 CAGED antigo
competênciadec	int	Competência da declaração	YYYYMM
unidadesaláriocódigo	int	Unidade do salário	5 mensal (mais comum)
valorsaláriofixo	float	Salário fixo	Sem variáveis

Escolaridade (gradeinstrução)

Código	Descrição
1	Analfabeto
2	Fundamental incompleto
3	Fundamental completo
4	Médio incompleto
5	Médio completo
6	Superior incompleto
7	Superior completo
8	Pós-graduação

Tamanho do estabelecimento (tamestabjan)

Código	Faixa de empregados
1	Até 4
2	5 a 9

3	10 a 19
4	20 a 49
5	50 a 99
6	100 a 249
7	250 a 999
8	1000+

A solução deste problema DEVE OBRIGATORIAMENTE ser buscada usando um algoritmo de aprendizado de máquina que não envolva serviços externos nem algoritmos relacionados a redes neurais artificiais (execução 100% na máquina local).

Critérios de avaliação

Organização e clareza do código: (40% da nota), incluindo testes unitários automatizados e incorporados na solução segundo as melhores práticas de mercado, comentários com a justificativa para as escolhas feitas na análise e na otimização. Durante a execução o código deve rodar EXCLUSIVAMENTE EM UMA MÁQUINA SEM CONEXÃO COM A INTERNET.

Qualidade do tratamento de dados e análise exploratória: (30% da nota) o que inclui tudo o que for feito antes da aplicação do algoritmo.

Score F1 do modelo em relação ao baseline do professor: (30% da nota): O professor usará seu baseline com um algoritmo extremamente simplista e comparará os resultados o score F1 da diferença entre as previsões e os resultados concretos. A nota será proporcional ao ganho de desempenho na base de testes DO PROFESSOR em relação à taxa de acertos do algoritmo de baseline.

Instruções para entrega

O trabalho deve ser entregue em UM arquivo ZIP contendo:

- o notebook Python ou apenas o código-fonte necessário para executar o tratamento de dados, a análise exploratória e o algoritmo;
- O arquivo de saída CSV com os dados de teste fornecidos pelo professor, acrescidos de uma coluna com as respostas previstas pelo seu algoritmo para as linhas correspondentes. A única diferença entre o arquivo fornecido pelo professor e o resultado da equipe deve ser a coluna com as previsões.

Observações gerais

O trabalho pode ser feito em equipes de até 4 alunos. A EQUIPE TODA É IGUALMENTE RESPONSÁVEL PELO SUCESSO DO TRABALHO.

CUIDADO: aqui está se avaliando tanto o resultado gerado quanto o código e algoritmo escolhidos. Apresente um código compreensível por todos os membros da equipe, especialmente quanto aos parâmetros escolhidos.

Não use este documento com ferramentas de IA pois o professor vê isso como uma atitude, hum... *contraproducente*. Ao pedir algo a uma IA, explique o que você precisa com as **SUAS** palavras.

É TERMINANTEMENTE PROIBIDO compartilhar arquivos entre equipes. Qualquer tentativa de fazer isso implicará na atribuição de nota ZERO a TODOS os membros de TODAS as equipes envolvidas. Casos suspeitos passarão por prova de autoria, portanto todos os membros da equipe devem saber como o código funciona e os motivos de cada escolha feita.

Cabe lembrar que compartilhar VERBALMENTE caminhos bem e mal sucedidos é permitido. O único cuidado é não compartilhar também os **eventuais valores de parâmetros de configuração, que devem ter uma diferença de no mínimo 10% para mais ou para menos em pelo menos um parâmetro da implementação para cada equipe.**